MODELAGEM ESTATÍSTICA | TRABALHO 1

O que explica o preço de um imóvel?

Regressão linear com dados de House Sales em King County, EUA (2014–2015)

Bloco 1 Os dados e o modelo simples (Seções 1 a 11)

Bloco 2 Modelo múltiplo, log e diagnósticos (Seções 12 a 19)

Bloco 3 Comparação, validação e escolha do modelo (Seções 20 a 26)

Base: 21.613 vendas realizadas entre maio de 2014 e maio de 2015

VISÃO GERAL

Roteiro da apresentação

Bloco 1 — Seções 1 a 11

Que dados temos e o que a área sozinha diz sobre o preço?

Auditoria, descrição e modelo de regressão simples.

Bloco 2 — Seções 12 a 19

Como melhorar o modelo e confiar nele?

Modelo múltiplo, resíduos, vendas atípicas, log e robustez.

Bloco 3 — Seções 20 a 26

Qual modelo escolher?

Comparação, mês, previsões em log, interações, localização, validação e seleção.

Resumo em quatro números

21.613

vendas analisadas

49% → 79%

do preço explicado (R^2 ajustado): só área contra modelo completo

261 → 167 mil

erro típico em US$: só área contra modelo completo

3.021 → 1.796

US$ por m²: efeito da área sozinha contra com outras características

Dados

Base limpa com critério explícito; revendas e vendas atípicas mantidas e tratadas.

Modelo

Qualidade e localização (CEP) pesam mais que o mês da venda.

Teste

O modelo completo também vence em imóveis nunca vistos no treino.

Área, qualidade da construção e localização explicam grande parte do preço, e essa conclusão se mantém em dados novos.

A pergunta e os dados

Pergunta

Qual a associação entre a área habitável e o preço de venda, e quanto da variação dos preços uma reta simples descreve? Depois, o que mais ajuda a explicar o preço?

Variável	Descrição	Unidade	Papel
price	Preço da venda	US$ nominais	Resposta
area	Área habitável (pés² × 0,0929)	m^2	Preditor principal
grade	Qualidade da construção	Escala de 1 a 13	Preditora
bathrooms	Banheiros	Contagem	Preditora
yr_built	Ano de construção	Ano	Preditora
lat	Latitude	Graus decimais	Preditora

Cada linha da base é uma venda; os resultados mostram associações, não causas.

Auditoria dos dados

21.613

vendas válidas, sem ausências nos campos essenciais

23

registros sinalizados para conferência (por exemplo, 0 banheiros); mantidos

176

imóveis vendidos mais de uma vez, somando 353 vendas

O que sai da base

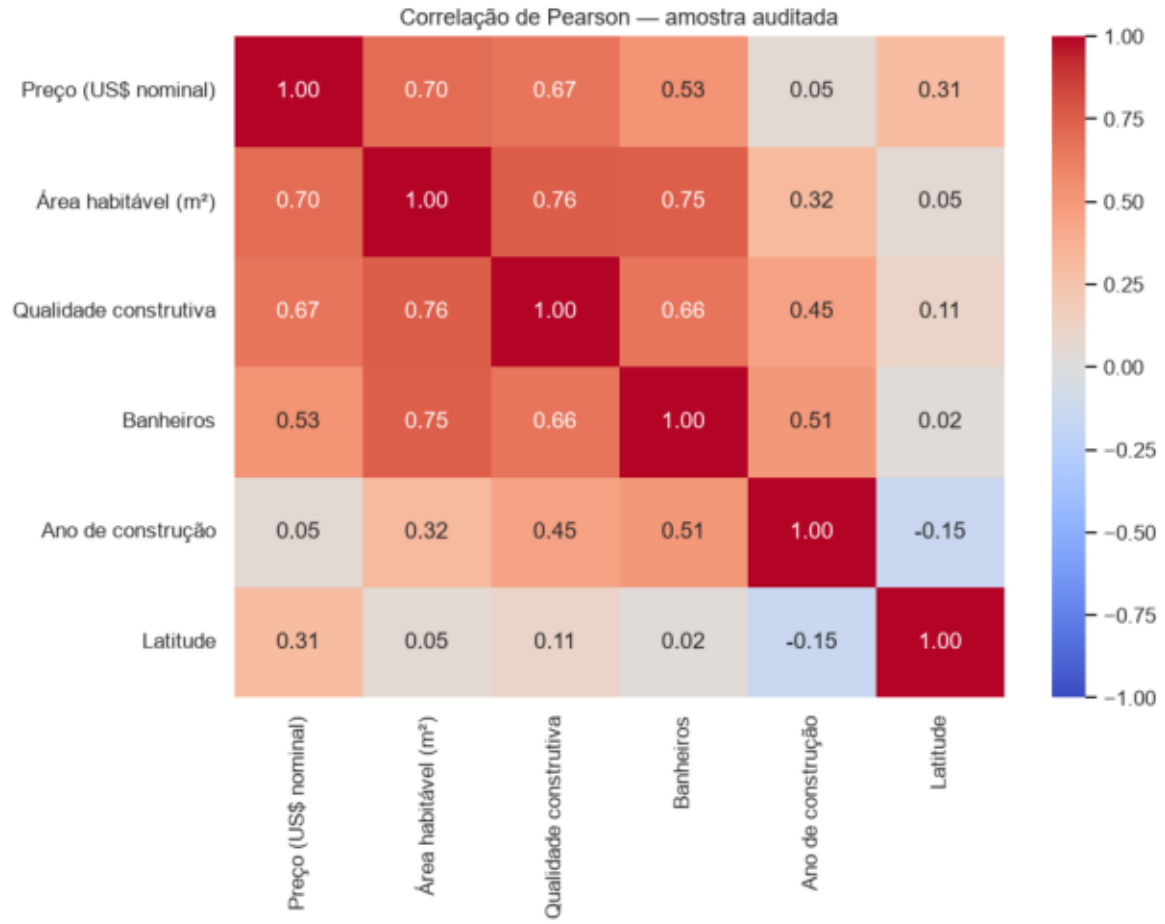
Apenas cópias idênticas de linhas e vendas sem dados essenciais válidos, cada uma registrada com o motivo e a linha de origem.

O que fica

Revendas e valores extremos de preço e área. Por causa das revendas, a incerteza é calculada agrupando as vendas do mesmo imóvel.

Dados tratados com critério claro; nada foi apagado por parecer estranho.

Olhando os dados



Preços muito assimétricos

Média de US$ 540 mil e mediana de US$ 450 mil, com máximo de US$ 7,7 milhões (assimetria 4,0).

Área, qualidade e banheiros

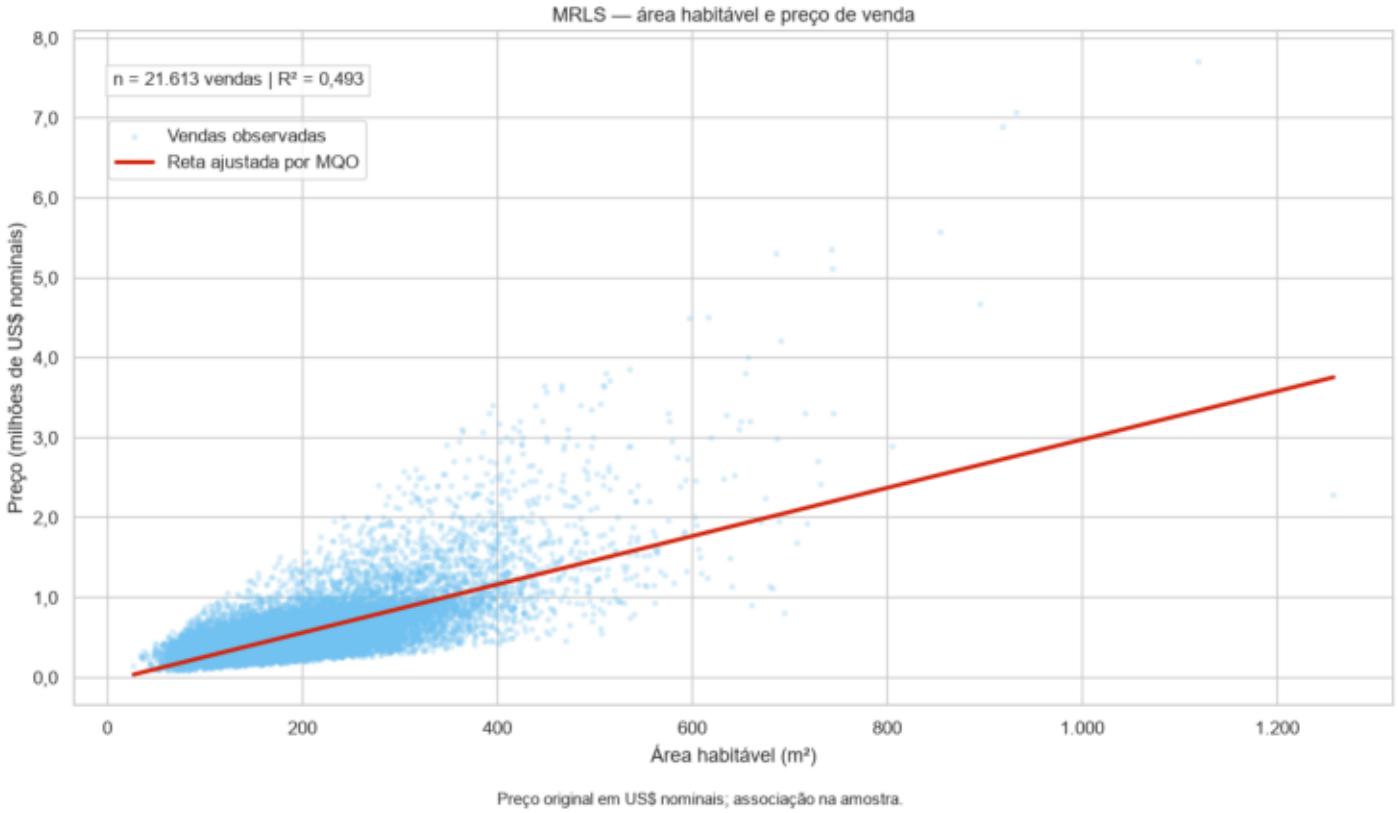
Todas associadas ao preço (0,70, 0,67 e 0,53).

Atenção

Elas também se associam entre si (0,75 a 0,76).

A área é a variável mais associada ao preço (0,70), seguida da qualidade (0,67).

Modelo simples: preço pela área



+ US$ 3.021

por m² a mais (IC 95%: 2.901 a 3.140)

49%

do preço descrito (R^2)

US$ 261 mil

erro típico do modelo

Leitura

Teste de Wald agrupado por imóvel: efeito da área não nulo ($p < 0,001$). É uma associação simples.

A reta simples explica cerca de metade do preço; falta explicar o resto.

Modelo múltiplo: mais características

Variável	Coeficiente	Unidade
Área	1.796	US$ por m²
Qualidade (grade)	122.655	US$ por ponto
Banheiros	37.075	US$ por banheiro
Ano de construção	−3.301	US$ por ano
Latitude	527.912	US$ por grau

Como ler

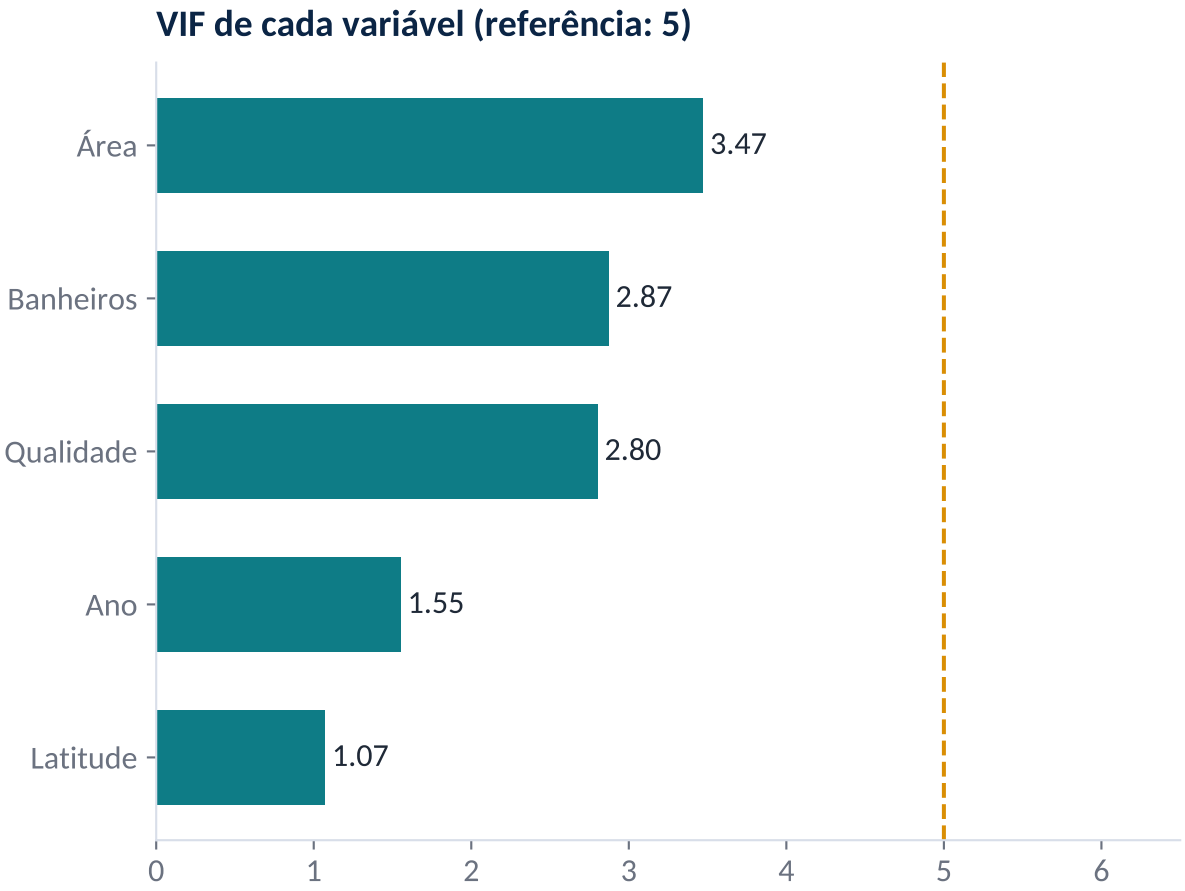
Cada coeficiente vale mantendo as outras variáveis constantes. Todos são significativos ($p < 0{,}001$).

Resultado

A área cai de 3.021 para 1.796 US$/m². R^2 sobe de 0,49 para 0,64 e o erro típico cai para US$ 219 mil.

Ao controlar outras características, o efeito da área cai e o modelo explica bem mais.

Diagnósticos: multicolinearidade e resíduos



Multicolinearidade

Todos os VIF ficam abaixo de 5 e a matriz tem posto completo: não há problema grave.

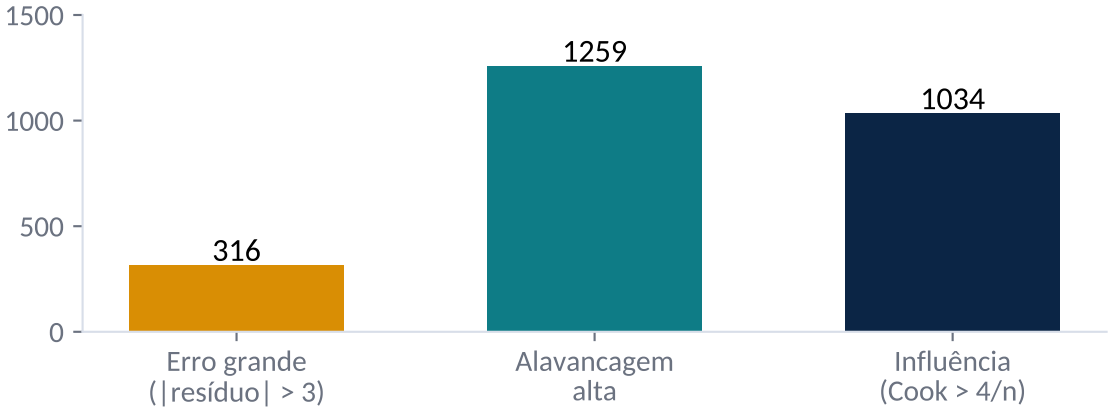
Resíduos em dólares

Caudas pesadas e tamanho do erro que muda com o preço, o que pede inferência robusta.

Variáveis distintas o bastante, mas os erros em dólares são irregulares: por isso usamos erros robustos.

Vendas que merecem atenção

Vendas sinalizadas por critério



Total

1.786 vendas (8%) têm ao menos um sinal. Sinal não é erro: nada foi removido automaticamente.

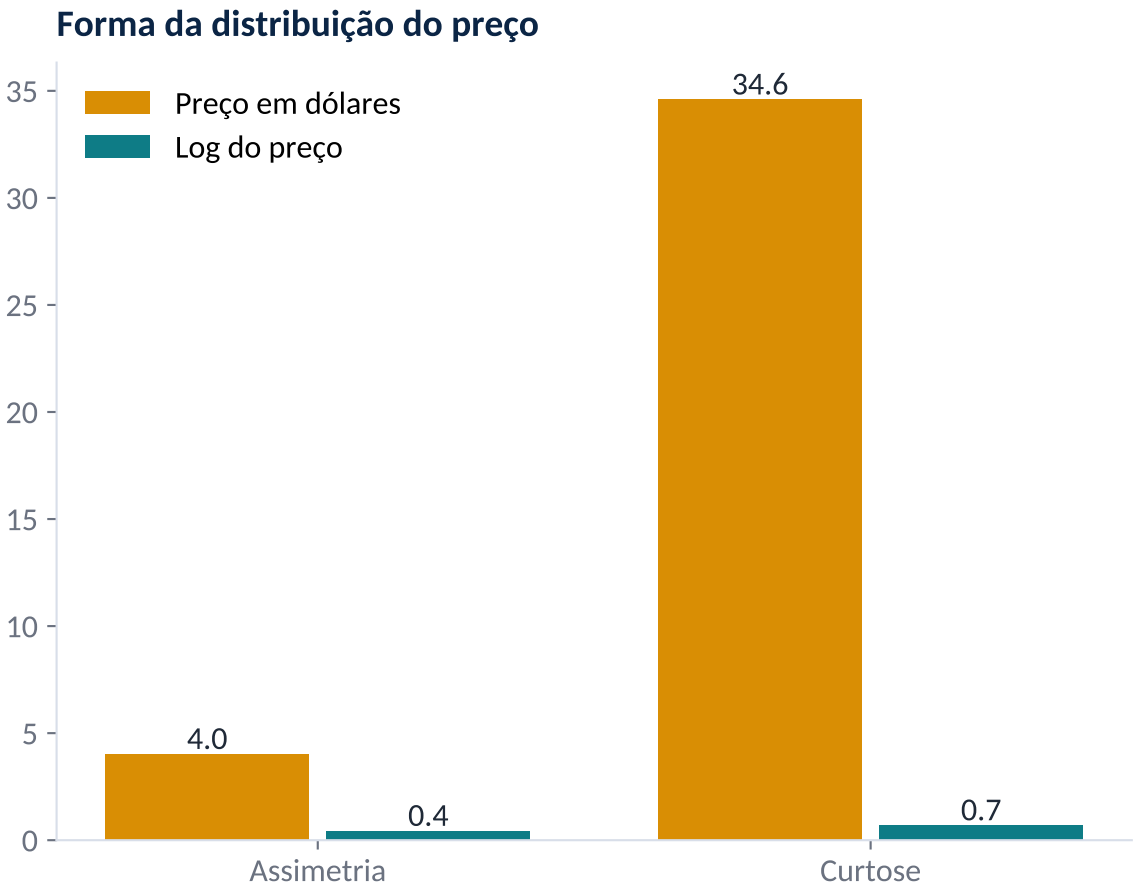
Três maiores influências (distância de Cook)

Linha	Preço	Área	Cook
7254	US$ 7,70 mi	1.119 m²	0,545
3916	US$ 7,06 mi	933 m²	0,428
9256	US$ 6,89 mi	919 m²	0,260

São imóveis grandes e caros, que puxam a reta.

Identificamos as vendas atípicas sem apagá-las e medimos o impacto na Seção 19.

Usando o log do preço



Efeito do log

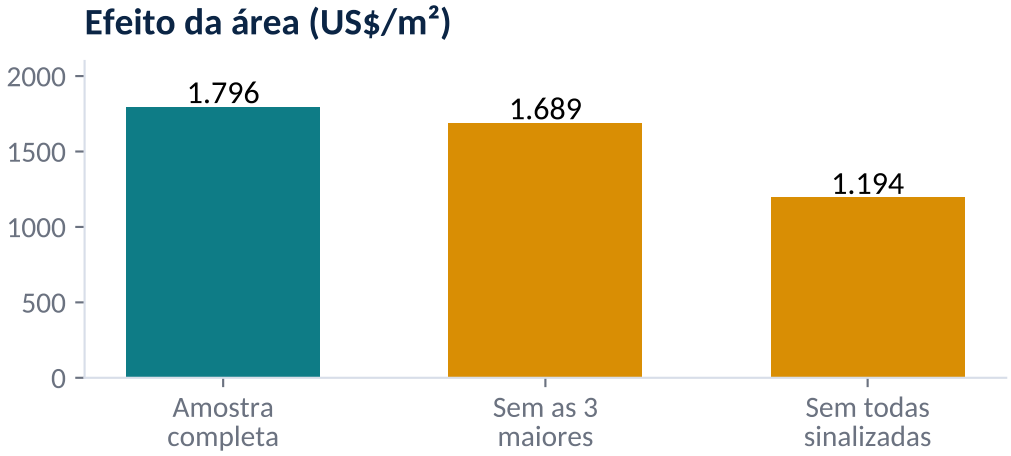
A cauda dos preços altos é comprimida e a distribuição fica quase simétrica.

Resíduos em log

Curtose próxima de 4 e assimetria próxima de 0,1. Ainda há variância não constante.

O log deixa preço e erros mais comportados e explica mais (R^2 de 0,64 para 0,74).

E se tirarmos as vendas atípicas?



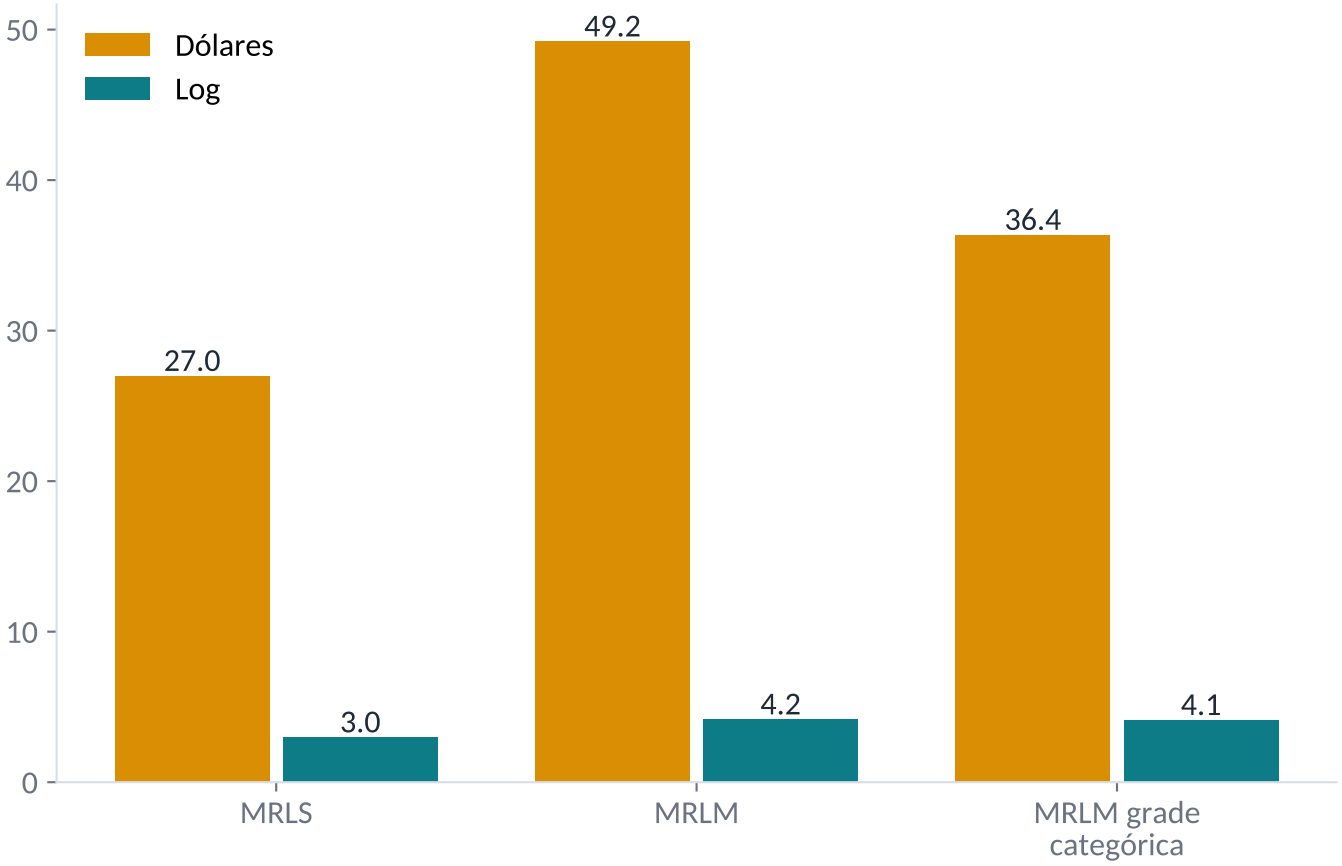
Variável	Completa	Sem sinalizadas
Área	1.796	1.194
Qualidade	122.655	101.419
Banheiros	37.075	33.341
Ano	−3.301	−2.324
Latitude	527.912	519.057

Sem as 3 maiores: −6%. Sem todas as sinalizadas: −34%.

O efeito segue positivo e relevante, mas depende bastante dos imóveis atípicos.

Síntese dos diagnósticos

Curtose dos resíduos (maior = caudas mais pesadas)



Em dólares

Erros com caudas pesadas (curtose até 49).

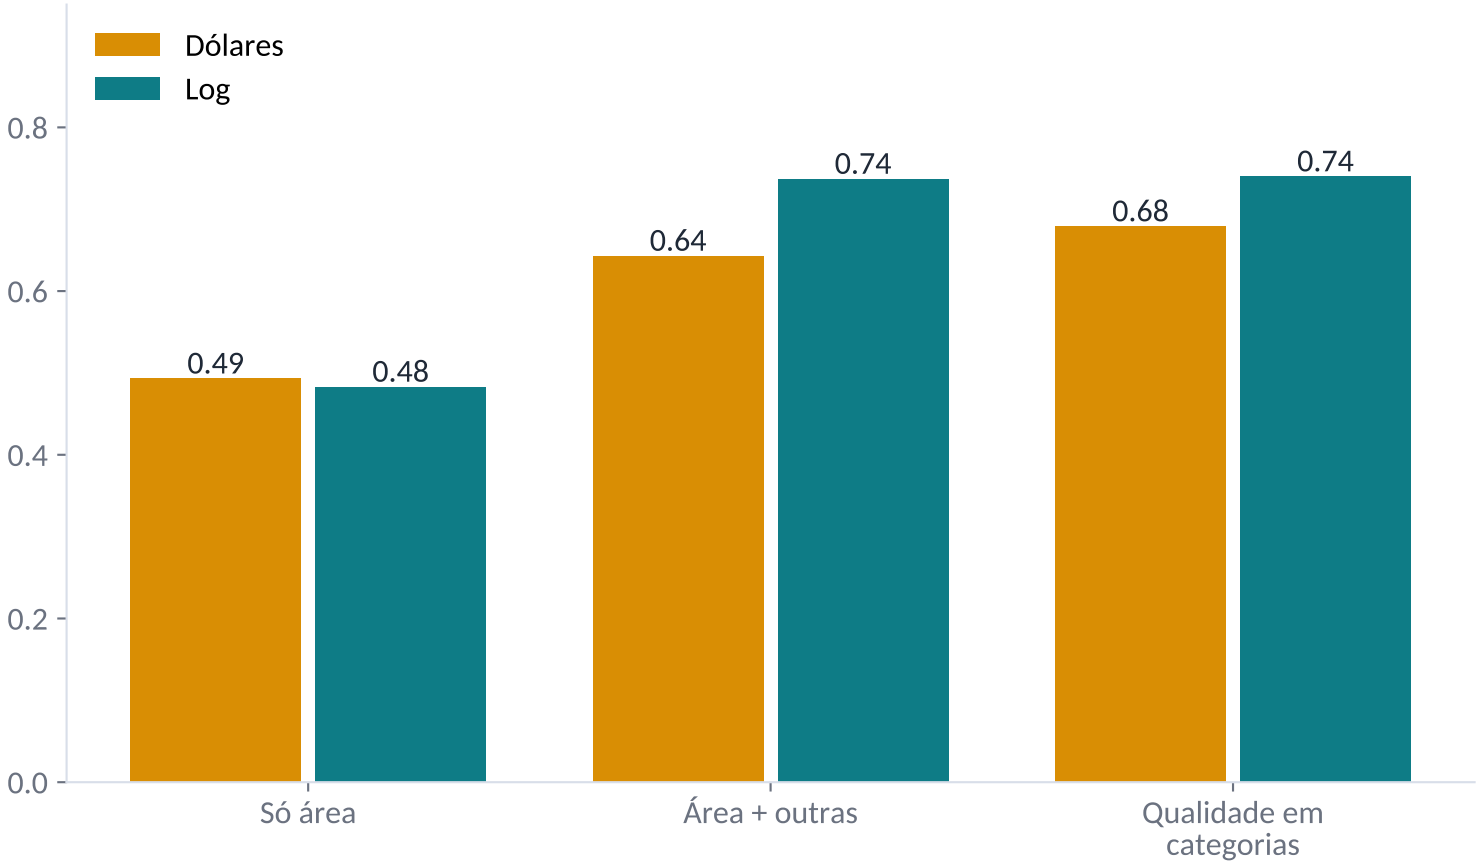
Em log

Só o MRLS em log não rejeita normalidade (p = 0,21). A variância não é constante em todos.

O log melhora a forma dos erros, mas a variância continua não constante nos seis modelos.

Qual modelo explica melhor?

R^2 ajustado: parcela do preço explicada



Leitura

Só a área explica cerca de metade; com outras características chega a 64% (dólares) e 74% (log).

Cuidado

Comparamos dólares com dólares e log com log, nunca entre escalas.

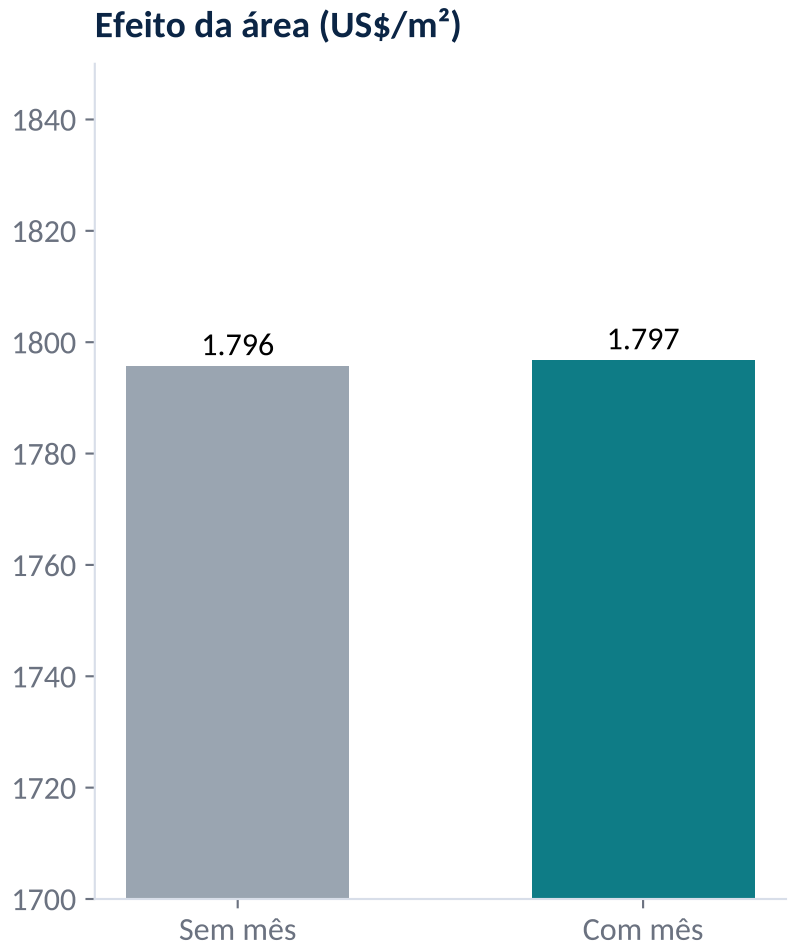
Mais variáveis explicam mais, e a melhora é estatisticamente real (p < 0,001).

O mês da venda importa?

Modelo	Efeito da área (US$/m²)	R² aj. (dólares)	R² aj. (log)
Sem controle de mês	1.795,68	0,643	0,737
Com controle de mês	1.796,73	0,645	0,740

Teste dos 12 efeitos

Conjuntamente significativos: F = 9,7 (dólares) e 20,8 (log).



O mês é significativo, mas não muda a conclusão sobre a área.

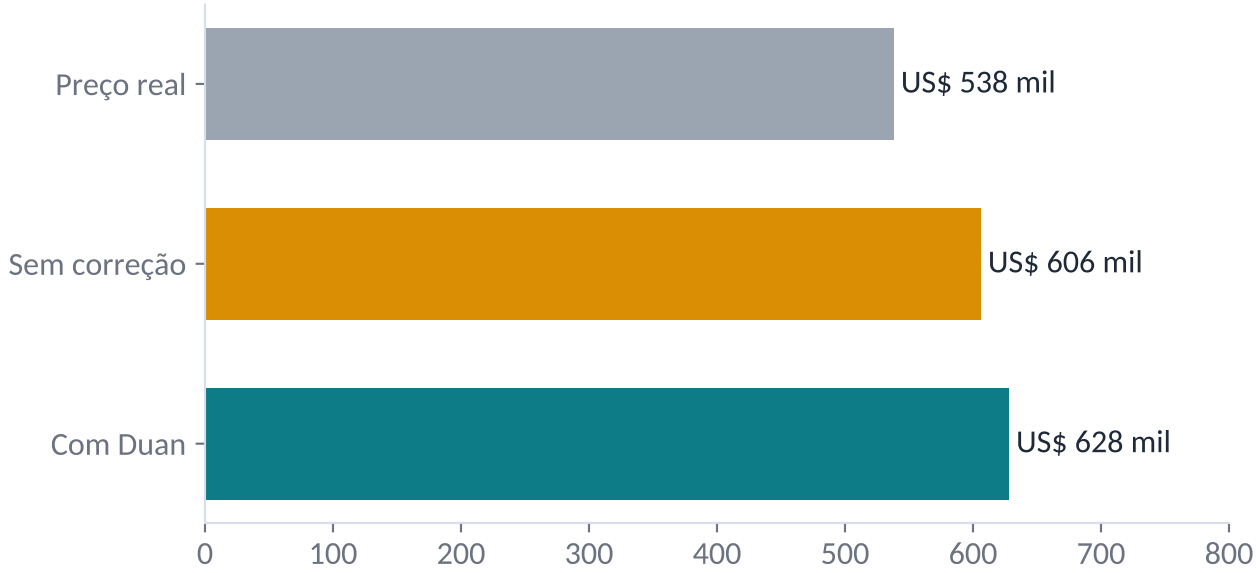
Voltando do log para dólares

1. O modelo prevê o log do preço

2. Desfazemos o log (exponencial)

3. Multiplicamos pelo fator de Duan (~1,04)

Exemplo: imóvel vendido por US$ 538.000



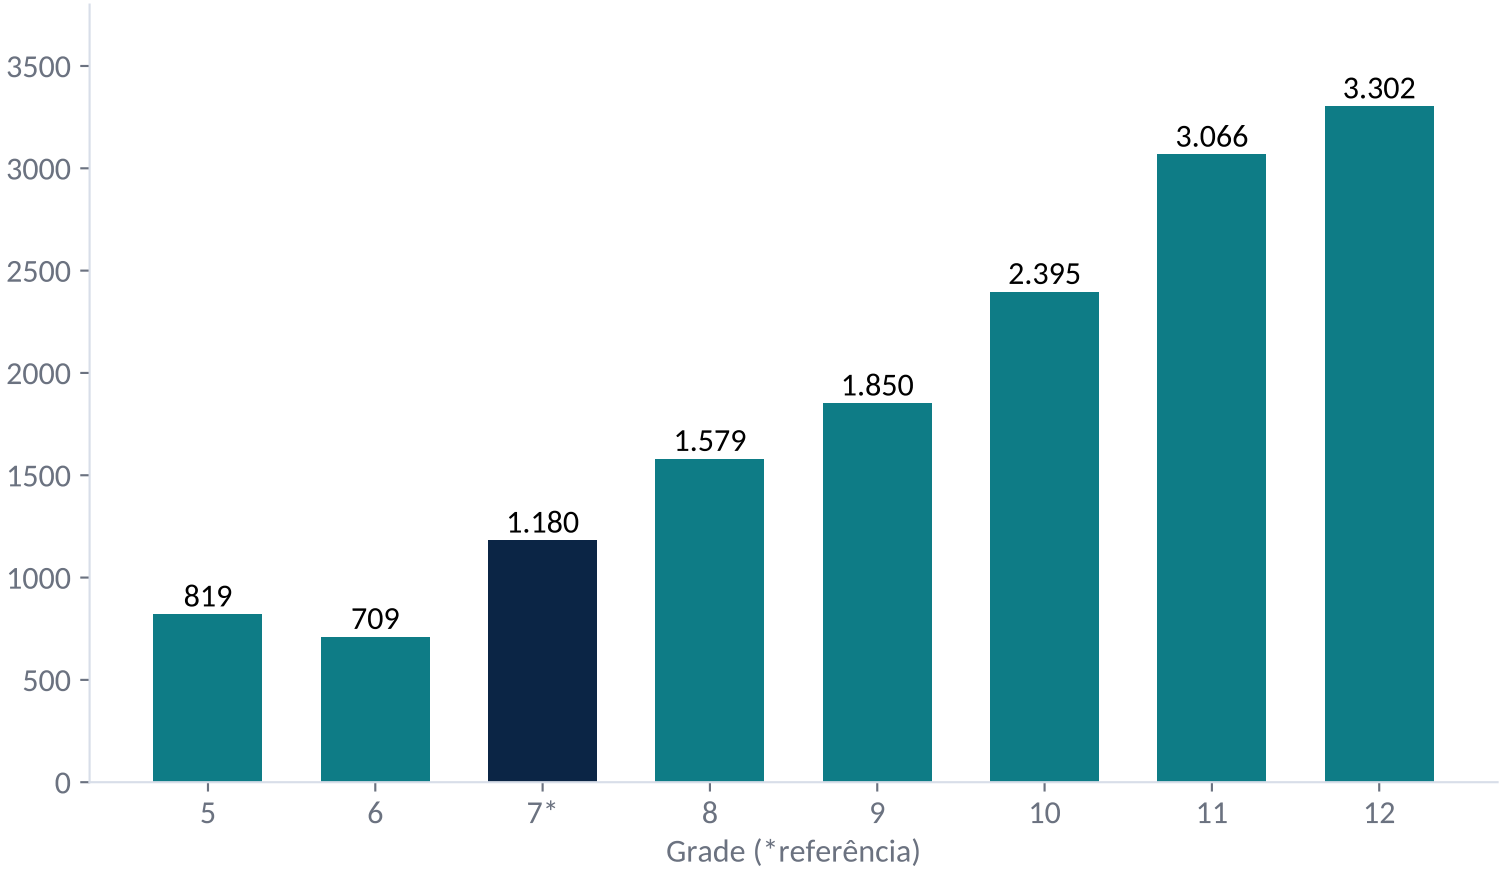
Atenção

Sem a correção a previsão sai baixa. Estas previsões usam os mesmos dados do ajuste: ainda não são teste.

Voltar do log pede uma correção de cerca de 4% (fator de Duan).

Área e qualidade trabalham juntas

Preço associado a +1 m², por nível de qualidade (US$)



Leitura

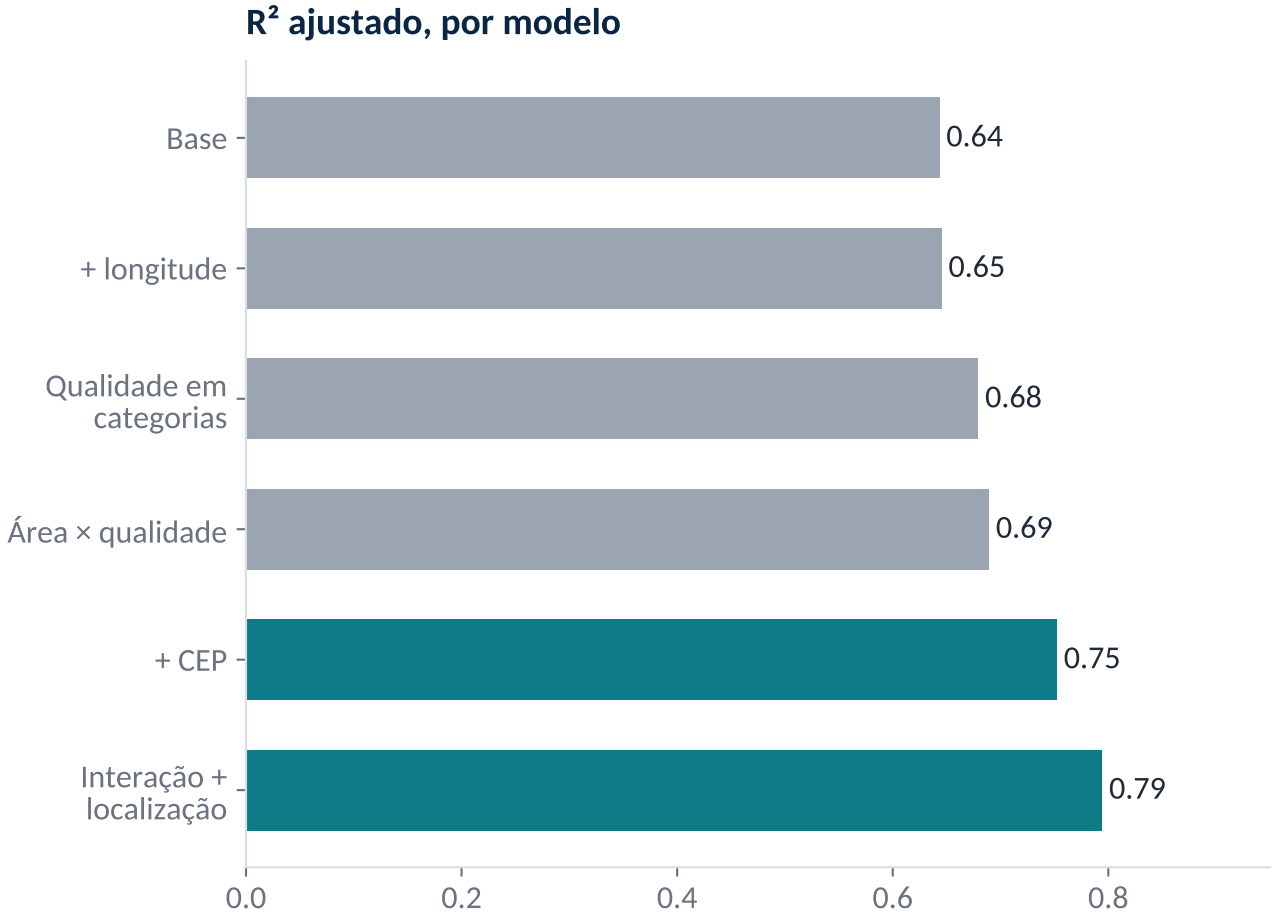
Em imóveis de alta qualidade cada m² vale muito mais (F = 31, p < 0,001).

Cuidado

Nos extremos há poucas vendas (grade 12: 90), então o intervalo é largo.

O efeito da área depende da qualidade do imóvel.

A localização melhora o modelo?



Leitura

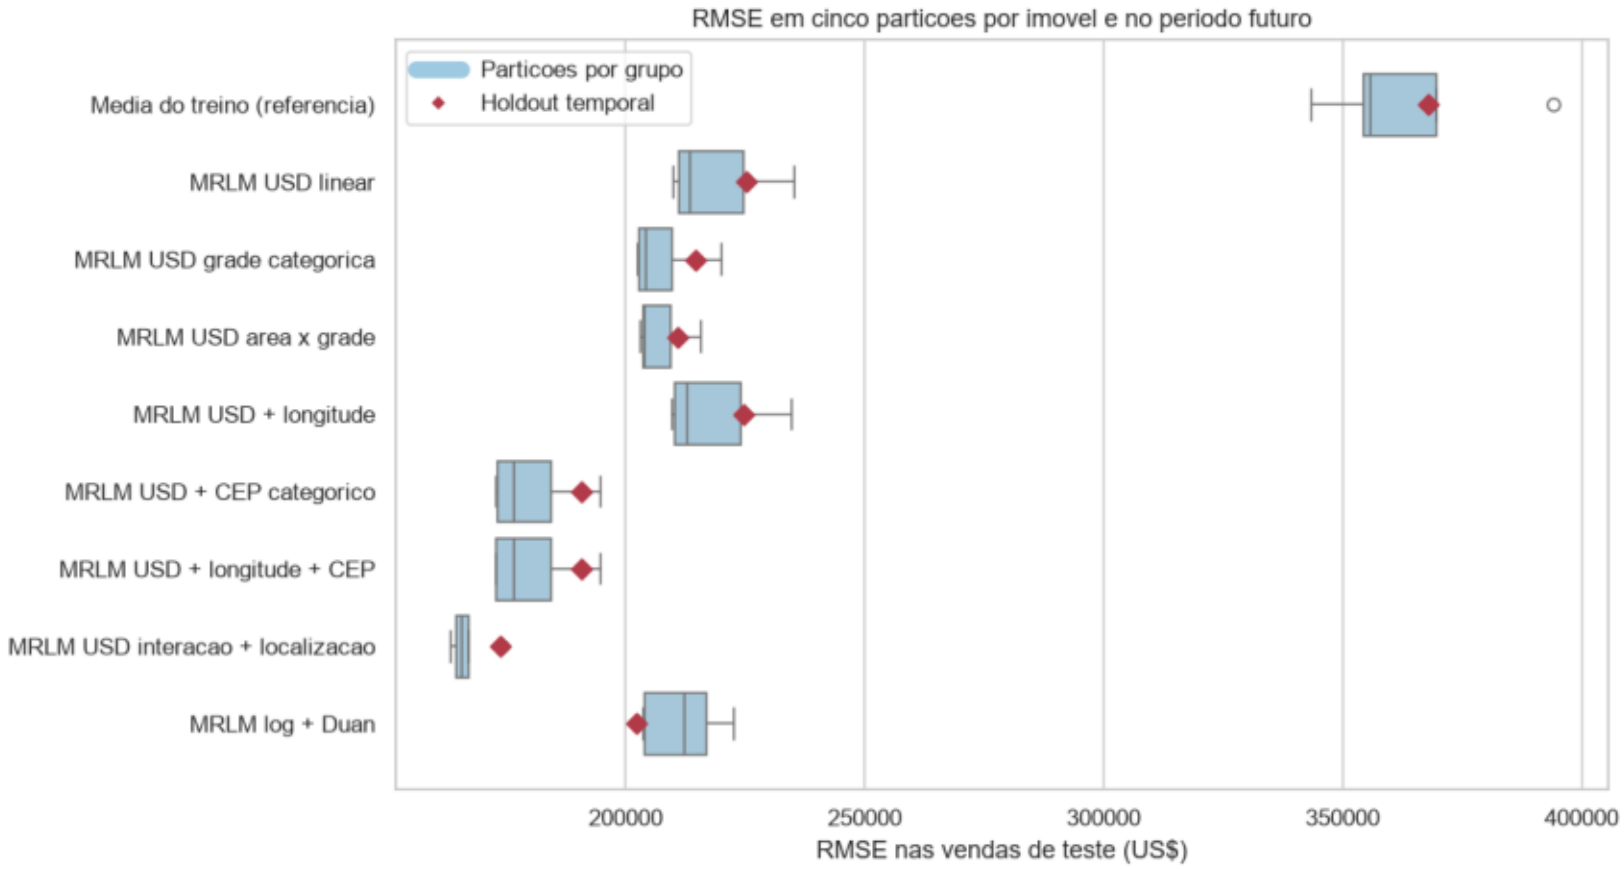
O CEP como categoria dá o maior salto (0,64 para 0,75). Com interação, chega a 0,79.

Custo

São 93 parâmetros. Ajustar bem o que já se tem não garante acertar imóveis novos.

A localização é o que mais melhora o ajuste, mas isso ainda precisa ser testado em dados novos.

Teste com imóveis que o modelo nunca viu: o desenho



Desenho

5 sorteios com 20% dos imóveis no teste e um corte no tempo (treino antes de 10/03/2015).

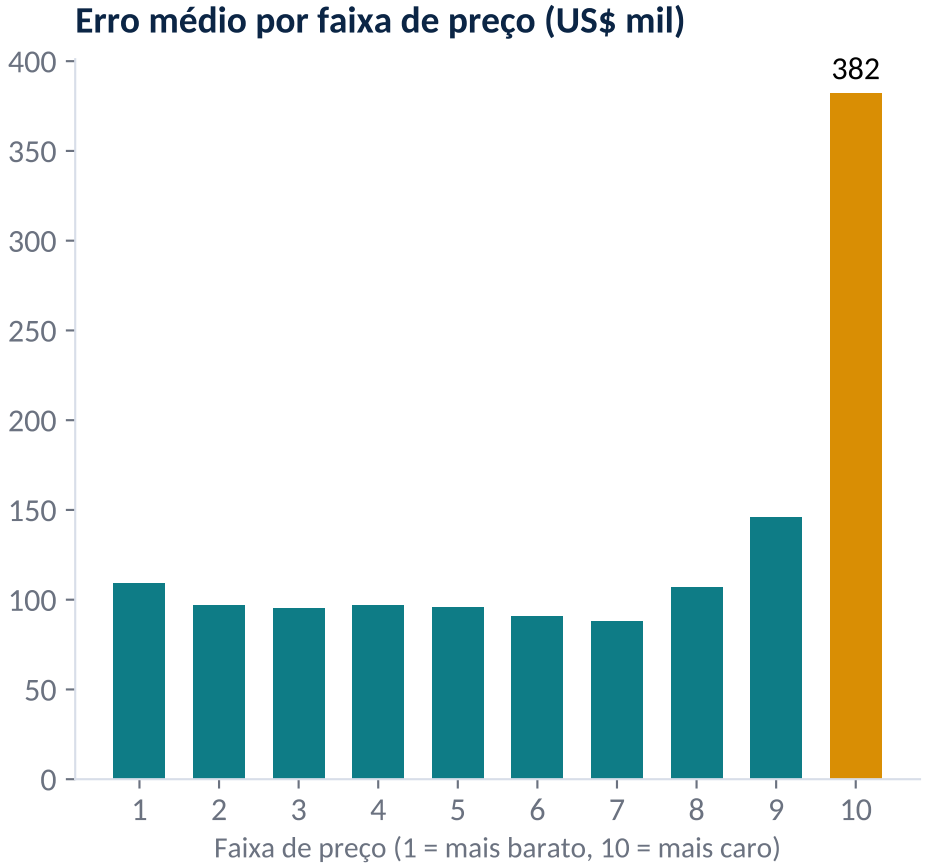
Sem vazamento

Nenhum imóvel nos dois lados; 91 vendas antigas de imóveis do teste saíram do treino.

Menor erro significa melhor modelo; o de interação com localização é o menor nos sorteios e no período futuro.

Teste com imóveis que o modelo nunca viu: os resultados

Modelo	R^2 teste	RMSE (US$ mil)	MAE (US$ mil)
Interação + localização	0,79	167	94
Com CEP	0,75	180	106
Log + Duan	0,66	212	120
MRLM linear	0,64	219	135
Só a média	0,00	364	234



O modelo completo vence também fora da amostra; o erro é muito maior nos imóveis mais caros.

Quais variáveis manter?

Cenário	Parâmetros	Explica (R^2 aj.)	Erro típico (US$)
Sem CEP, sem mês	24	69%	204 mil
Sem CEP, com mês	36	69%	204 mil
Com CEP, sem mês	93	79%	167 mil
Com CEP, com mês	105	80%	166 mil

Seleção por BIC

Forward, Backward e Stepwise chegam ao mesmo modelo em cada cenário.

Com CEP

A latitude sai do modelo, pois o CEP já carrega a localização.

O CEP é o bloco mais importante; o mês ajuda pouco.

FECHAMENTO

Conclusão

1. O que explica o preço

Além da área, a qualidade da construção e a localização explicam boa parte do preço.

2. O que melhora a previsão

A combinação área × qualidade com localização, e não o mês da venda.

3. Limites

Estudo observacional: associação, não causa. Imóveis atípicos mantidos e erro maior nos mais caros.

Limitações e cuidados

Observacional

Associações não são causas; podem existir fatores não medidos.

Resíduos

Não normais e com variância não constante; usamos erros robustos.

Seleção exploratória

Intervalos não incluem a incerteza da escolha do modelo.

Venda única de grade 1

Alavancagem próxima de 1; mantida, mas sem inferência confiável.

APÊNDICE

Glossário rápido

Termo	Em português simples
Resíduo	Erro do modelo: preço real menos preço previsto
R^2	Parcela da variação do preço explicada pelo modelo (0 a 100%)
Log do preço	Escala que reduz o peso dos imóveis muito caros
Fator de Duan	Ajuste de ~4% para voltar do log para dólares
Validação	Testar o modelo em imóveis que ele não usou para aprender
CEP categórico	Dar a cada CEP o seu próprio efeito no preço
Interação	Efeito de uma variável que depende de outra
BIC	Critério que equilibra ajuste e número de parâmetros

APÊNDICE

Perguntas prováveis

Pergunta	Resposta curta
Por que erros agrupados por imóvel?	Revendas violam a independência entre vendas.
Resíduos não normais invalidam?	Não: usamos inferência robusta e validação fora da amostra.
Por que o fator de Duan?	Exponenciar o log dá a média geométrica, não a média.
CEP não é overfitting?	A validação por imóveis confirmou o ganho (R^2 de teste 0,75).
Por que não remover atípicos?	São sinais para investigar; o impacto foi medido na Seção 19.
Isso mostra causalidade?	Não: dados observacionais mostram associação.